Assurance of Learning

STAT6157049 - Data Mining and Visualization

D1392 - Dr. Ir. I Gusti Agung Anom Yudistira, M.Si.

Pengembangan Model Regresi Logistik dan Prediksi serta Analisis dari Dataset Risiko Tahap Awal Diabetes

Amanda Sugito

Anthony

Hazel Zaki Adityo

Marcell Prasetyo

Satya Darma Padmakumara

Vanessa Santoso

Computer Science and Statistics

BINUS University

2024/2025

Abstrak

Penelitian ini bertujuan untuk mengembangkan model prediksi risiko diabetes tahap awal menggunakan regresi logistik berbasis machine learning, dengan data sekunder dari *Early Stage Diabetes Risk Prediction Dataset* yang berisi 520 sampel dan 16 atribut risiko. Melalui eksplorasi data, termasuk histogram, barplot, boxplot, dan heatmap, penelitian ini mengidentifikasi distribusi data dan hubungan antar variabel. Hasil penelitian ini diharapkan untuk memberikan kontribusi signifikan bagi tenaga kesehatan, masyarakat, dan pengembangan model prediktif lebih lanjut, sekaligus meningkatkan kesadaran pentingnya deteksi dini untuk mencegah komplikasi diabetes.

Kata Kunci: risiko diabetes, regresi logistik, machine learning

1. Pendahuluan

1.1. Latar Belakang

Diabetes merupakan salah satu penyakit mematikan yang terus meningkat setiap tahunnya menurut World Health Organization terutama di Indonesia yang dapat menyebabkan komplikasi, seperti stroke, amputasi, gagal ginjal, penyakit jantung, tersumbatnya aliran darah, dll. Diabetes merupakan penyakit yang ditandai dengan tingginya kadar gula di dalam tubuh. Salah satu faktor penyebab utamanya adalah kurangnya hormon insulin di dalam pankreas yang dikarenakan tubuh tidak menghasilkan cukup insulin untuk kadar gula yang berlebih.

Diabetes sering tidak terdeteksi oleh pengidapnya yang menyebabkan timbulnya komplikasi-komplikasi secara mendadak. Faktor utama pengidap penyakit diabetes adalah pola makan yang tidak sehat yang disebabkan karena kurangnya pemahaman tentang faktor-faktor penyebab diabetes.

Kurangnya pemahaman masyarakat tentang pencegahan dan pengelolaan risiko diabetes merupakan tantangan utama dalam melawan diabetes terutama di Indonesia.

Melalui laporan ini, dengan melakukan penelitian dan membahas berbagai risiko yang dapat menyebabkan diabetes, termasuk gaya hidup yang tidak sehat, dan pentingnya edukasi dan pemahaman diabetes sejak dini. Dengan memahami laporan ini, diharapkan seluruh masyarakat dapat lebih sadar akan pentingnya

mencegah penyakit diabetes dan komplikasi yang menyertai melalui faktor-faktor risikonya

1.2. Rumusan Masalah

1.2.1. Bagaimana membangun model prediksi yang akurat untuk mendeteksi risiko diabetes pada tahap awal berdasarkan dataset *Early Stage Diabetes Risk Prediction*?

1.2.2. Apa saja faktor yang memiliki pengaruh signifikan terhadap prediksi risiko diabetes dari dataset?

1.2.3. Mengapa model prediksi berbasis *machine learning* dapat memberikan hasil yang lebih efektif dibandingkan metode konvensional dalam mendeteksi risiko diabetes?

1.3. Tujuan Penelitian

1.3.1. Mengetahui cara membangun model prediksi yang akurat untuk mendeteksi risiko diabetes pada tahap awal berdasarkan dataset *Early Stage Diabetes Risk Prediction.*

1.3.2. Mengetahui faktor yang memiliki pengaruh signifikan terhadap prediksi risiko diabetes dari dataset.

1.3.3. Mengetahui alasan model prediksi berbasis machine learning dapat memberikan hasil yang lebih efektif dibandingkan metode konvensional dalam mendeteksi risiko diabetes.

1.4. Manfaat Penelitian

1.4.1. Manfaat Umum

Penelitian ini bertujuan untuk meningkatkan pemahaman dan kesadaran masyarakat mengenai risiko diabetes, sehingga memungkinkan deteksi dini dan intervensi tepat waktu untuk mencegah komplikasi serius serta memperbaiki kualitas hidup penderita.

1.4.2. Bagi Peneliti

Penelitian ini memberikan kontribusi dalam pengembangan model prediksi berbasis *machine learning* untuk deteksi risiko diabetes. Model

ini dapat digunakan sebagai referensi bagi peneliti lain dalam mengeksplorasi hubungan antara berbagai faktor risiko dan diabetes.

1.4.3. Bagi Masyarakat

Hasil penelitian ini dapat digunakan sebagai dasar pengembangan strategi edukasi dan intervensi kesehatan masyarakat, yang bertujuan untuk meningkatkan pemahaman tentang pentingnya gaya hidup sehat dan manajemen risiko diabetes sejak dini.

1.4.4. Bagi Tenaga Kesehatan

Model prediksi yang dikembangkan memberikan alat yang lebih akurat bagi tenaga kesehatan untuk mengidentifikasi individu dengan risiko tinggi diabetes. Hal ini memungkinkan pengambilan keputusan yang lebih baik dalam memberikan saran, diagnosis, dan perawatan yang sesuai.

1.4.5. Bagi Penelitian di Masa Depan

Penelitian ini membuka peluang untuk pengembangan lebih lanjut dalam bidang prediksi penyakit kronis, khususnya diabetes. Hasil ini dapat digunakan sebagai pijakan untuk mengatasi keterbatasan dalam penelitian sebelumnya dan mengintegrasikan faktor-faktor risiko tambahan dalam model prediksi.

2. Metode Penelitian

Jurnal ini menggunakan data sekunder untuk melakukan penelitiannya, dimana data telah diambil dari situs web *UC Irvine Machine Learning Repository* dan memiliki nama *Early Stage Diabetes Risk Prediction.* Format *file* yang didapat merupakan .csv dan *software* yang digunakan untuk penelitiannya adalah RStudio dan Google Colab dimana ada dipergunakannya bahasa pemrograman R. Dataset ini berisikan 520 sampel yang didapat dari kuesioner langsung terhadap pasien *Sylhet Diabetes Hospital* di Bangladesh, dengan 16 atribut yang mencakup faktor risiko diabetes seperti usia, BMI, dan pola hidup.

2.1. Persiapan Data

Penelitian ini menggunakan library *tidyverse* dan *corrplot* yang terkenal akan kemampuannya pada bidang *data science* untuk mempercepat dan mempermudah proses penelitian.

```
> library(tidyverse)
> library(corrplot)
> data <- read.csv(file.choose())
```

Dataset memiliki nama file "diabetes_data_upload.csv" yang diimpor ke dalam RStudio sebagai *dataframe* bernama "data", impor dilakukan menggunakan *function* read.csv(). *Dataframe* yang diimpor memiliki 520 *observations* dan 17 *variables* dengan rincian:

2.1.1. Age: Integer, rentang 16 - 90 tahun

2.1.2. Gender: Categorical, Female atau Male (0 atau 1).

2.1.3. Polyuria, Polydipsia, sudden.weight.loss, weakness, Polyphagia, Genital.thrush, visual.blurring, Itching, Irritability, delayed.healing, partial.paresis, muscle.stiffness, Alopecia, Obesity: Semua variabel ini bernilai kategorikal No atau Yes (0 atau 1).

2.1.4. Class: Variabel target dengan dua nilai, Negative atau Positive (0 atau 1).

```
> head(data)
```

Age	Gender	Polyuria	Polydipsia	sudden.weight.loss	weakness	Polyphagia	Genital.thrush	visual.blurring	Itching
<int>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>
40	Male	No	Yes	No	Yes	No	No	No	Yes
58	Male	No	No	No	Yes	No	No	Yes	No
41	Male	Yes	No	No	Yes	Yes	No	No	Yes
45	Male	No	No	Yes	Yes	Yes	Yes	No	Yes
60	Male	Yes	Yes	Yes	Yes	Yes	No	Yes	Yes
55	Male	Yes	Yes	No	Yes	Yes	No	Yes	Yes

Irritability	delayed.healing	partial.paresis	muscle.stiffness	Alopecia	Obesity	class
<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>
No	Yes	No	Yes	Yes	Yes	Positive
No	No	Yes	No	Yes	No	Positive
No	Yes	No	Yes	Yes	No	Positive
No	Yes	No	No	No	No	Positive
Yes	Yes	Yes	Yes	Yes	Yes	Positive
No	Yes	No	Yes	Yes	Yes	Positive

2.2. Eksplorasi Data

Eksplorasi data dilakukan pada penelitian ini untuk memahami struktur dan pola dalam dataset yang telah dipilih. Proses ini mencakup visualisasi dan analisis untuk mengidentifikasi distribusi data, hubungan antar variabel, dan potensi adanya ketidakseimbangan dalam data. Tujuan dari proses ini adalah untuk mendapatkan wawasan awal tentang karakteristik data yang akan digunakan dalam analisis lebih lanjut, khususnya dalam pembuatan model prediktif.

2.2.1. Histogram

Distribusi variabel Age divisualisasikan menggunakan histogram untuk menunjukkan frekuensi umur pada dataset. Histogram ini membantu mengidentifikasi rentang usia yang paling umum dalam dataset serta pola distribusinya, seperti apakah data terpusat pada kelompok umur tertentu atau tersebar merata.

2.2.2. Bar Chart

Distribusi kelas target class (Positive dan Negative) divisualisasikan menggunakan barplot. Barplot ini memberikan informasi mengenai jumlah pasien dalam setiap kategori risiko diabetes, sehingga mempermudah identifikasi ketidakseimbangan kelas dalam dataset.

2.2.3. Box Plot

Hubungan antara variabel Age dan class divisualisasikan menggunakan boxplot. Visualisasi ini memberikan wawasan mengenai distribusi umur berdasarkan kategori class, termasuk median, kuartil, dan potensi keberadaan outliers yang mungkin berpengaruh pada analisis model.

2.2.4. Heat Map

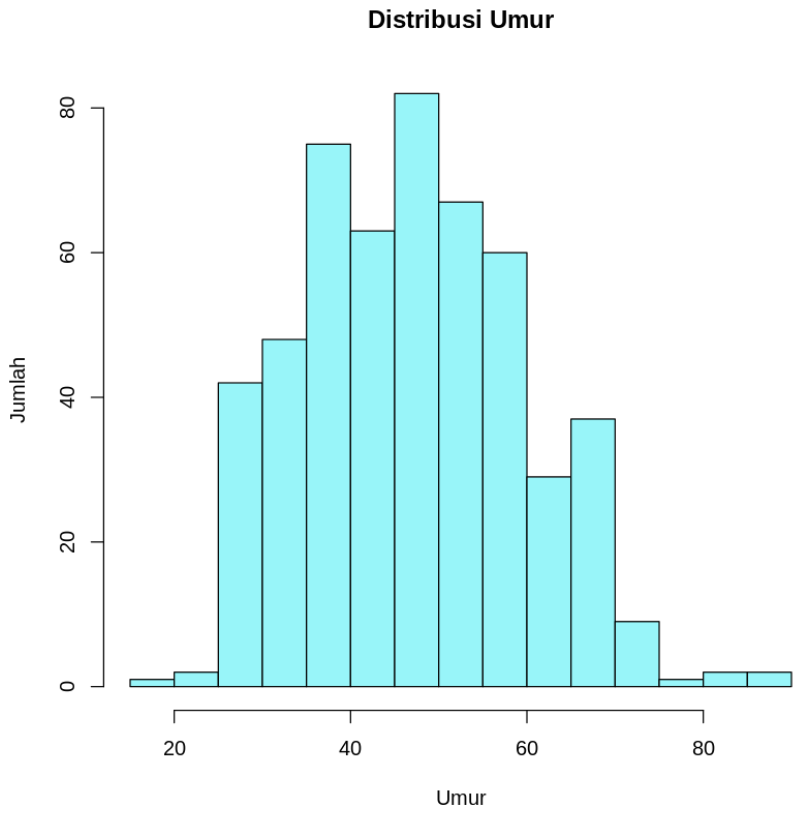
Analisis korelasi dilakukan antara lima variabel utama, yaitu Age, Gender, visual.blurring, sudden.weight.loss, dan weakness. Korelasi ini divisualisasikan dalam bentuk heatmap untuk memahami hubungan linear antara variabel, yang membantu menentukan relevansi masing-masing variabel terhadap target prediksi.

3. Hasil dan Pembahasan

3.1. Visualisasi Data

3.1.1. Distribusi Umur

```
> hist(data$Age, main = "Distribusi Umur",
+      xlab = "Umur", ylab = "Jumlah", col = "#98F5F9")
```

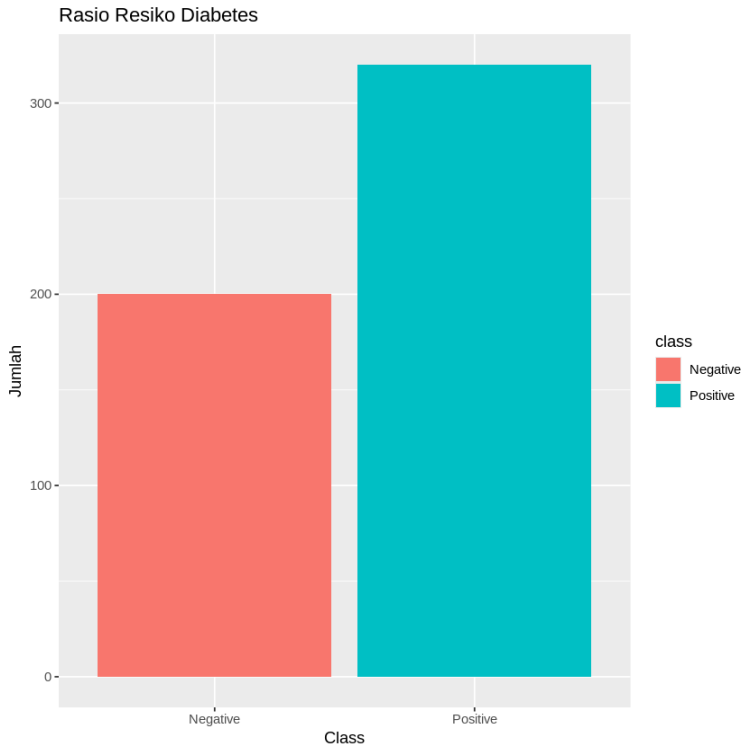


Sumbu X (Horizontal) menjelaskan tentang umur. Sumbu Y (Vertikal) menjelaskan tentang jumlah orang yang terkena penyakit. Melalui diagram batang diatas, mayoritas usia penderita penyakit diabetes berada di angka 25 hingga 75 tahun (dewasa hingga lanjut usia).

- Semakin meningkat umurnya maka semakin menurunnya metabolisme tubuh dan meningkatnya risiko terpapar penyakit.
- Semakin meningkat umurnya maka akan semakin menurun aktivitas sehari-hari akibat dari penuaan yang berujung perubahan gaya hidup
- Faktor lain dapat memengaruhi seperti keturunan, obesitas, DLL yang dapat timbul kapan saja.

3.1.2. Bar

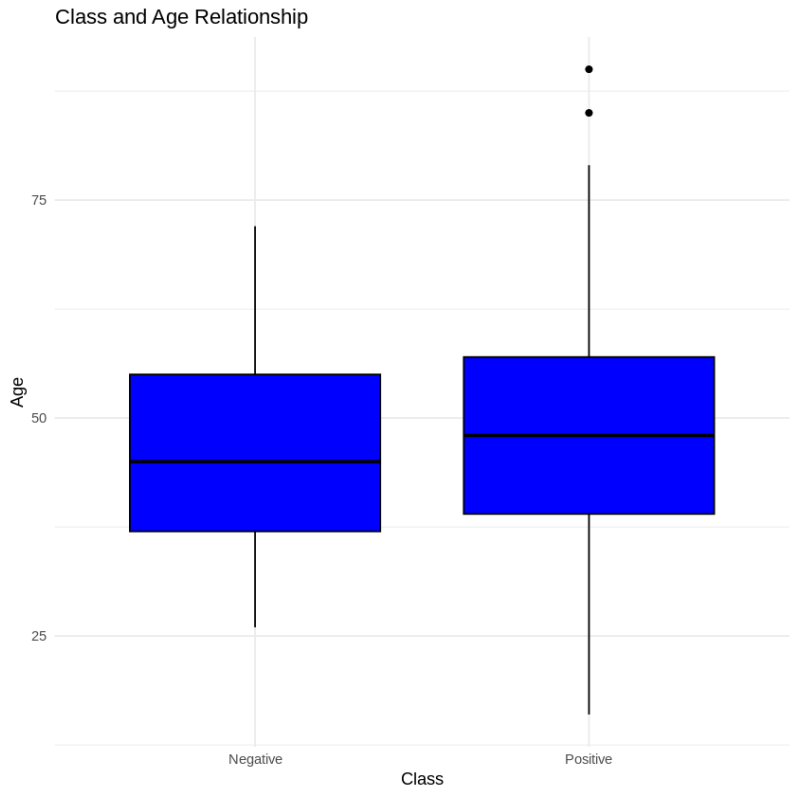
```
> ggplot(data, aes(x = class, fill = class)) +
+     geom_bar() + xlab("Class") + ylab("Jumlah") +
+     ggtitle("Rasio Resiko Diabetes")
```



Bar Plot di atas menggambarkan rasio resiko seseorang terkena diabetes, dengan dua kategori utama: individu yang tidak beresiko terkena diabetes (*negative*) dan individu yang berisiko (*positive*). Dari visualisasi tersebut, terlihat bahwa jumlah individu dalam kategori *positive* lebih besar dibandingkan dengan kategori *negative*. Hal ini menunjukkan bahwa, berdasarkan data yang dianalisis, lebih banyak individu yang berisiko terkena diabetes.

3.1.3. Box

```
> ggplot(data, aes(x = class, y = Age)) +
+     geom_boxplot(fill = "blue", color = "black") +
+     labs(title = "Class and Age Relationship",
+     x = "Class", y = "Age") +
+     theme_minimal()
```

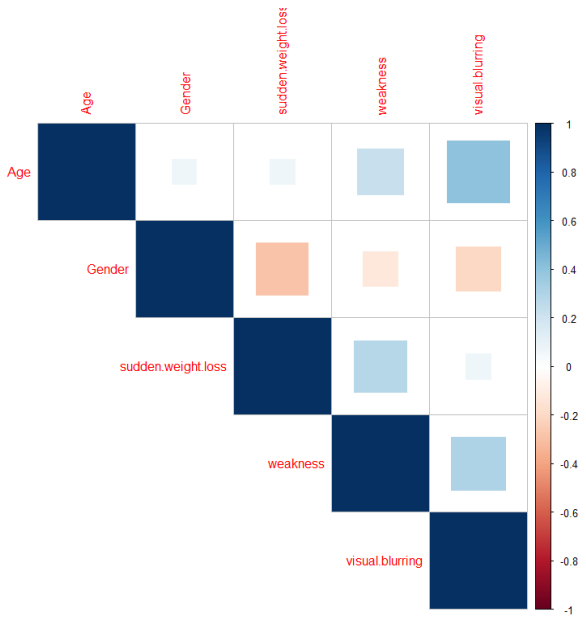


Sumbu X (Horizontal) menjelaskan mengenai terkena penyakit diabetes dan tidak terkena penyakit diabetes. Sumbu Y (Vertikal) menjelaskan tentang umur. Melalui Box plot diatas, dapat dilihat data pertama, tiga pemusatan data (mean, median, modus), dan data terakhir berdasarkan umur terkena penyakit diabetes. Dari data tersebut dapat dilihat rata-rata umur terkena diabetes, umur yang paling sering terkena diabetes, dll yang dapat membantu dalam observasi penelitian tentang risiko terkenanya penyakit diabetes terhadap umur seseorang.

3.1.4. Heatmap

```
> data$Gender <- ifelse(data$Gender == "Male", 1, 0)
```

```
> data$weakness <- ifelse(data$weakness == "Yes", 1, 0)
> data$sudden.weight.loss <-
ifelse(data$sudden.weight.loss ==
+ "Yes", 1, 0)
> data$visual.blurring <- ifelse(data$visual.blurring
==
+ "Yes", 1, 0)
> data$class <- ifelse(data$class == "Positive", 1, 0)
> corr_column <- c(1, 2, 5, 6, 9)
> new_data <- data[, corr_column]
> corr <- cor(new_data)
> corrplot(corr, method = "square", type = "upper")
```



Gambar diatas adalah *heatmap* yang memvisualisasikan matriks korelasi. Warna dalam *heatmap* merepresentasikan nilai korelasi dengan warna biru tua yang memiliki arti korelasi positif yang tinggi (+1), warna merah dengan arti korelasi negatif (-1), dan warna putih korelasi mendekati nol. Melalui *heatmap* diatas, ada beberapa kesimpulan yang dapat diambil yaitu:

- Korelasi antara "Age" dengan variabel lain tampak lemah dan menunjukkan bahwa "age" tidak memiliki hubungan linear yang kuat dengan variabel lainnya.
- Melihat variabel "Sudden_Weight_Loss" dapat dilihat memiliki korelasi positif yang moderat dengan variabel "Weakness". Hal ini dapat dilihat dari warna biru yang lebih gelap dibandingkan dengan hubungan lain. Melalui observasi berikut, dapat disimpulkan bahwa

individu yang mengalami “Sudden_Weight_Loss” cenderung juga mengalami “Weakness”.

- Variabel “Visual_Blurring” memiliki korelasi yang tampak lebih signifikan dengan variabel “Weakness” dibandingkan dengan variabel lainnya, yaitu “Age” atau “Gender”.

3.2. Pemodelan

3.2.1. Pembagian Data

Pembagian data adalah langkah penting dalam proses pengembangan model untuk memastikan bahwa model yang dibuat mampu belajar secara efektif dan dapat diandalkan ketika digunakan pada data baru. Hal ini memastikan bahwa model tidak hanya “menghafal” data pelatihan, tetapi juga mampu membuat prediksi yang akurat pada data yang belum pernah dilihat sebelumnya.

Pada penelitian kali ini, data dibagi menjadi dua bagian:

a) Training Data
   - Sebesar 80% dari total dataset digunakan sebagai data pelatihan (Training Data). Data ini digunakan untuk melatih model sehingga model dapat mengenali pola dan hubungan antara variabel independen (karakteristik) dengan variabel target.
   - Selama proses pelatihan, model mempelajari hubungan ini untuk meminimalkan kesalahan prediksi melalui iterasi dan optimisasi parameter.

b) Test Data
   - Sebesar 20% dari total dataset digunakan sebagai data pengujian (Test Data). Data ini tidak digunakan selama proses pelatihan sehingga memberikan gambaran tentang kemampuan model untuk memprediksi data baru.

- Dengan mengevaluasi performa model pada test data, dapat dipastikan bahwa model tidak mengalami overfitting, yaitu kondisi di mana model terlalu terfokus pada pola data pelatihan sehingga tidak dapat memprediksi dengan baik pada data baru.

3.2.2. Algoritma

Algoritma adalah model belajar dari data untuk membuat prediksi atau keputusan. Algoritma bertindak sebagai instruksi atau prosedur matematis yang membantu komputer menemukan pola, memahami struktur data, dan membuat hubungan antara input dan output. Berikut adalah beberapa peran utama algoritma:

a) Mempelajari Pola dari Data

Algoritma digunakan untuk menganalisis data, menemukan pola, dan memahami hubungan antar variabel.

b) Membangun Model Prediktif

Algoritma membantu membangun model yang dapat memprediksi nilai target berdasarkan data baru.

c) Mengoptimalkan Kinerja Model

Algoritma meminimalkan kesalahan prediksi dengan mengatur parameter model menggunakan teknik seperti *gradient descent*.

d) Mengatasi Tantangan pada Data

Algoritma dirancang untuk menangani berbagai jenis data, termasuk data yang tidak lengkap, tidak seimbang, atau memiliki banyak fitur sehingga tetap menghasilkan model yang efektif.

e) Generalisasi ke Data Baru

Algoritma memastikan model dapat bekerja baik pada data baru maupun data yang digunakan saat pelatihan (Test data).

f) Adaptasi untuk Berbagai Tugas

Algoritma dapat disesuaikan untuk berbagai jenis tugas, seperti:

- Klasifikasi: Menentukan kategori data, seperti algoritma *decision tree* atau *logistic regression*.
- Regresi: Memperkirakan nilai kontinu, seperti algoritma *linear regression*.
- Clustering: Mengelompokkan data yang mirip, seperti *k-means*.
- Deteksi Anomali: Mendeteksi data yang tidak biasa, seperti *isolation forest*.

3.2.3. Model Prediksi

```
> library(caret)
> library(pROC)
```

Pertama, dimulai dengan memuat library Caret (Classification and Regression Training) untuk mempermudah pembuatan, pelatihan, dan evaluasi model yang dibuat dan library pROC (Receiver Operating Characteristic Analysis) untuk mengevaluasi performa dari model yang berklasifikasi biner.

```
> set.seed(123)
> trainIndex <- createDataPartition(data$class, p = 0.8,
+                                   list = FALSE)
> trainData <- data[trainIndex, ]
> testData <- data[-trainIndex, ]
> Logistic_Regression_Model <- glm(class ~., data = trainData,
+                                  family = 'binomial')
> summary(Logistic_Regression_Model)
```

Ditetapkan sebuah seed agar hasil pembagian data selalu konsisten setiap kali code digunakan. Selanjutnya, dibagi dataset sebesar 80% untuk "trainData" yang digunakan untuk pelatihan dan 20% untuk "testData", yang digunakan untuk pengujian serta membuat "Logistic_Regression_Model" menggunakan function glm (Generalized

Linear Model) dengan variabel target “class” dan keseluruhan kolom lainnya sebagai prediktor (~.). Lalu, digunakan function summary() untuk menampilkan hasil model yang mengandung koefisien, signifikansi, dan deviasi null serta deviasi residual.

```
> Probability <- predict(Logistic_Regression_Model,
+                        testData, type = 'response')
> Predict_Class <- ifelse(Probability > 0.5, 1, 0)
```

Selanjutnya, dibuatkan variabel “Probability” menggunakan function predict(), dengan model yang sudah dilatih untuk memprediksi probabilitas “class” berdasarkan keseluruhan karakteristik yang ada di dalam “testData” dengan tipe responsi “response” agar hasil prediksi model dikonversi menjadi nilai probabilitas (0 - 1). Lalu, dilanjutkan dengan mengkategorikan nilai-nilai probabilitas tersebut ke dalam kelas tertentu dan disimpan dalam variabel “Predict_Class”. Jika nilai probabilitasnya melebihi 0.5, maka prediksi kelasnya adalah “1”, dan sebaliknya, jika nilai probabilitasnya tidak lebih besar dari 0.5, maka prediksi kelasnya adalah “0”.

```
> Predict_Class <- factor(Predict_Class, levels = c("0", "1"))
> Predict_Class <- factor(Predict_Class, levels = c(0, 1),
+                         labels = c("NEGATIVE", "POSITIVE"))
> testData$class <- factor(testData$class, levels = c(0, 1),
+                          labels = c("NEGATIVE", "POSITIVE"))
```

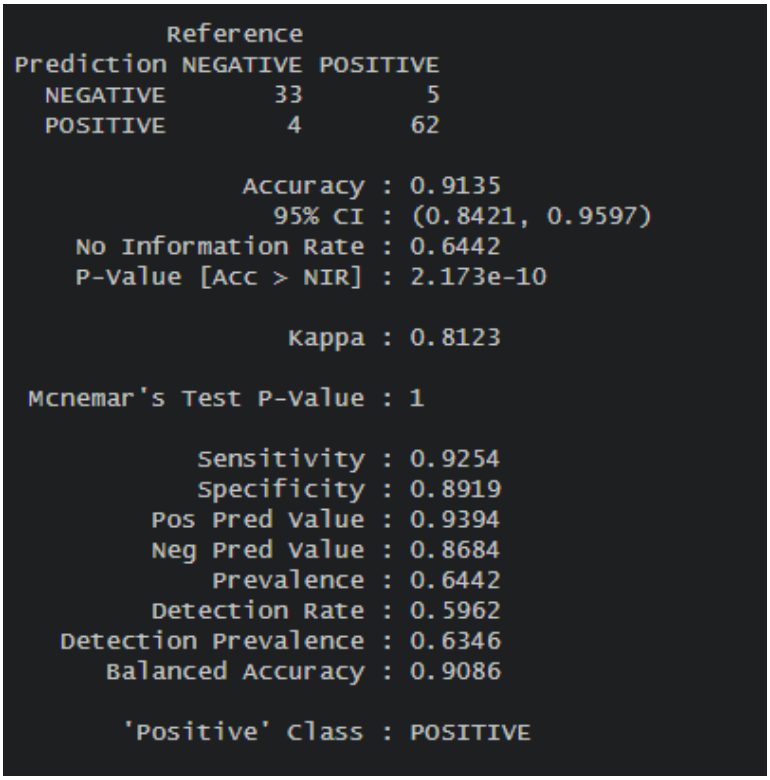
Setelah itu, digunakan function factor() untuk mengkonversi variabel “Predict_Class” menjadi tipe data faktor untuk mewakili data kategorik dengan level tertentu, dan mengubah labels dari level tersebut menjadi “POSITIVE” untuk prediksi kelas 1 dan “NEGATIVE” untuk prediksi kelas 0. Lalu, dilakukan hal yang sama di kolom “class” pada “testData” untuk mempermudah perbandingan antara prediksi model (Predict_Class) dan data yang asli (testData$class).

```
> Confusion_Matrix <- confusionMatrix(as.factor(Predict_Class),
+                                     as.factor(testData$class),
+                                     positive = "POSITIVE")
> Confusion_Matrix
```

```
> ROC <- roc(testData$class, Probability)
> AUC <- auc(ROC); AUC
```

Terakhir, dibuatlah Confusion Matrix untuk mengevaluasi akurasi, dan sensitivitas pada model prediksi yang telah dibuat, yang disimpan dalam variabel "Confusion_Matrix". Lalu, digunakan function roc() untuk mendapatkan kurva hubungan antara tingkat positif sejati (sensitivitas) dan tingkat positif palsu serta auc() untuk menampilkan hasil luas dibawah kurva dari ROC.

3.2.4. Hasil Model



```
          Reference
Prediction NEGATIVE POSITIVE
  NEGATIVE       33        5
  POSITIVE        4       62

               Accuracy : 0.9135
                 95% CI : (0.8421, 0.9597)
    No Information Rate : 0.6442
    P-Value [Acc > NIR] : 2.173e-10

                  Kappa : 0.8123

 Mcnemar's Test P-Value : 1

            Sensitivity : 0.9254
            Specificity : 0.8919
         Pos Pred Value : 0.9394
         Neg Pred Value : 0.8684
             Prevalence : 0.6442
         Detection Rate : 0.5962
   Detection Prevalence : 0.6346
      Balanced Accuracy : 0.9086

       'Positive' Class : POSITIVE
```

Dari gambar diatas, dapat disimpulkan bahwa model regresi logistik mempunyai akurasi yang baik, yaitu sebesar 91.35% dan juga balance accuracy yang baik dengan yaitu sebesar 90.86%. Lalu, ada nilai Kappa yang cukup baik sebesar 81.23%, yang menunjukkan besar kesepakatan antara model prediksi dan data yang aslinya. Terakhir, ada nilai Sensitivity yang mengindikasikan kemampuan model untuk mendeteksi kelas positif sebesar 92.54% dan nilai Specificity yang mengindikasikan kemampuan model untuk mendeteksi kelas negatif sebesar 89.19%.

4. Kesimpulan

Penelitian ini berhasil membangun model regresi logistik dari risiko diabetes yang didasarkan pada dataset *Early Stage Diabetes Risk Prediction*. Model yang dikembangkan menunjukkan tingkat akurasi sebesar 91.35%, yang menunjukkan bahwa model ini mampu mendeteksi risiko diabetes pada tahap awal dengan baik. Selain itu, model ini juga memiliki nilai sensitivitas yang tinggi (92,54%) dan spesifisitas yang baik (89,19%), yang menunjukkan kemampuan model dalam mengidentifikasi pasien dengan risiko diabetes kelas positif dan negatif dengan cukup efektif. Faktor-faktor seperti gejala klinis dan pola hidup terbukti memiliki pengaruh signifikan terhadap prediksi risiko diabetes, yang semakin memperkuat pentingnya pemantauan kondisi kesehatan dan gaya hidup.

Hasil dari penelitian ini memberikan kontribusi penting dalam pengembangan sistem prediksi berbasis machine learning untuk mendeteksi risiko diabetes secara lebih akurat dan cepat. Selain itu, penelitian ini dapat digunakan untuk meningkatkan kesadaran masyarakat tentang pentingnya deteksi dini dan pencegahan diabetes melalui pemahaman yang lebih baik tentang faktor-faktor risikonya. Model ini juga membuka peluang untuk penelitian lebih lanjut dalam bidang prediksi penyakit kronis lainnya dan dapat digunakan sebagai dasar bagi tenaga medis dalam memberikan diagnosis serta perawatan yang lebih tepat.

5. Daftar Pustaka

Rokom (2024, Januari 10) *Saatnya Mengatur Si Manis*. *Sehat Negeriku.* https://sehatnegeriku.kemkes.go.id/baca/blog/20240110/5344736/saatnya-mengatur-si-manis/

Diahwahyuningtyas, A. & Hardiyanto, S. (2023, Maret 20). *Diabetes Tipe 2: Gejala, Penyebab, Faktor Risiko, Komplikasi, dan Pencegahannya*. *Kompas.com*. https://www.kompas.com/tren/read/2023/03/20/090600965/diabetes-tipe-2--gejala-penyebab-faktor-risiko-komplikasi-dan-pencegahannya?page=all#:~:text=KOMPAs.com%20%2D%20Diabetes%20tipe%202,tidak%20dapat%20membuat%20cukup%20insulin.

Waluyo, D. (2024, Juli 19). *Cegah Dini Ancaman Diabetes. Indonesia.go.id.*

https://indonesia.go.id/kategori/editorial/8401/cegah-dini-ancaman-diabetes?lang=1

Ahmed, Nayeem & Hassan, Syed & Hussain, Md. (2022). *Applications of Machine Learning for Diabetes Prediction*. https://www.researchgate.net/publication/380021137_Applications_of_Machine_Learning_for_Diabetes_Prediction

Dataset

Early Stage Diabetes Risk Prediction - UCI Machine Learning Repository